Análisis de Componentes Principales

Dr. Cs. Miguel Pari Soto y Dr. Cs. Claver Pari Soto

PCA y SVD

- **Reducir la dimensionalidad** de datos complejos
- **Comprimir información** manteniendo la esencia de los datos
- **Identificar patrones** ocultos en conjuntos de datos
- **Optimizar el almacenamiento** y procesamiento de información

Introducción Matemática

Producto punto de vectores

Sean los vectores $\vec{x}$ y $\vec{y}$ con m componentes

$$\vec{x} = [x_1, x_2, ..., x_m]$$

$$\vec{y} = [y_1, y_2, ..., y_m],$$

entonces el producto punto se define como

$$\vec{x} \cdot \vec{y} = x_1 y_1 + x_2 y_2 + ... + x_m y_m$$

Matrices

La suma de matrices se hace sumando los elementos correspondientes de las dos matrices del mismo tamaño

$$A = \begin{bmatrix} -1 & 2 & 4 \\ 2 & -3 & -1 \end{bmatrix}_{2\times 3} \quad B = \begin{bmatrix} 3 & 4 \\ 1 & 7 \\ -1 & 1 \end{bmatrix}_{3\times 2}$$

$$AB = \begin{bmatrix} [-1 \;\; 2 \;\; 4] \cdot [3 \;\; 1 \;\; -1] & [-1 \;\; 2 \;\; 4] \cdot [4 \;\; 7 \;\; 1] \\ [2 \;\; -3 \;\; -1] \cdot [3 \;\; 1 \;\; -1] & [2 \;\; -3 \;\; -1] \cdot [4 \;\; 7 \;\; 1] \end{bmatrix}$$

$$AB = \begin{bmatrix} -5 & 14 \\ 4 & -14 \end{bmatrix}_{2\times 2}$$

$$AB = A \times B$$

Multiplicación de vectores (o matrices) por escalar

$$2\begin{bmatrix} 2 & -4 \end{bmatrix} = \begin{bmatrix} 4 & -8 \end{bmatrix}$$

$$3\begin{bmatrix} 1 \\ -2 \end{bmatrix} = \begin{bmatrix} 3 \\ -6 \end{bmatrix}$$

$$-2\begin{bmatrix} 1 & -2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} -2 & 4 \\ -6 & -8 \end{bmatrix}$$

Espacio vectorial

- Es un conjunto de vectores donde cualquier combinación lineal de vectores de ese conjunto también pertenece al espacio.
- Una combinación lineal se hace multiplicando escalares a los vectores y sumando los vectores resultantes, de la forma $a\vec{x} + b\vec{y}$, donde a y b son escalares
- En procesamiento de señales, una señal de tiempo discreto con n muestras puede representarse como un vector en el espacio vectorial $\mathbb{R}^n$
- En control, estados del sistema pueden representarse en espacios vectoriales de dimensión igual al número de variables de estado.

Base de espacio vectorial

- Es un conjunto mínimo de vectores linealmente independientes que generan todo el espacio.
- Ningún conjunto con menos vectores podrá generar el espacio.
- Ejemplo: $[1, 0]$ y $[0, 1]$ forman una base para el espacio 2-D. Cualquier $[x, y]$ en el espacio 2-D se puede escribir como $[x, y] = x[1, 0] + y[0, 1]$

Autovalores y autovectores

- Un autovector es un vector $\vec{x}$ distinto de cero que satisface $A\vec{x} = \lambda\vec{x}$
- λ es el autovalor correspondiente

Sean

$$A = \begin{bmatrix} 2 & 2 \\ 5 & -1 \end{bmatrix} \quad \text{y} \quad \vec{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \implies A\vec{x} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}; \qquad \vec{x} \text{ no es un autovector}$$

Por otro lado, si

$$A = \begin{bmatrix} 2 & 2 \\ 5 & -1 \end{bmatrix} \quad \text{y} \quad \vec{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \implies A\vec{x} = \begin{bmatrix} 4 \\ 4 \end{bmatrix} = 4\vec{x} = \lambda\vec{x}; \qquad \vec{x} \text{ es un autovector}$$

y $\lambda = 4$ es su autovalor correspondiente

Autovalores y autovectores

- Una matriz M puede ser descompuesta usando autovectores
- Los autovectores forman una base
- Los autovalores más grandes son los más *influyentes*
- Podemos reducir la dimensionalidad ignorando los autovalores *pequeños*

Cómo calcular los autovectores y autovalores

Estadística

Sean dos vectores

$$\vec{x} = [x_1 \ x_2 \ \dots \ x_n] \ \text{y} \ \vec{y} = [y_1 \ y_2 \ \dots \ y_n]$$

Media:

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Varianza:

$$\sigma_x^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2}{n - 1}$$

Covarianza:

$$\text{cov}(\vec{x}, \vec{y}) = \frac{(x_1 - \bar{x})(y_1 - \bar{y}) + \cdots + (x_n - \bar{x})(y_n - \bar{y})}{n - 1}$$

Estadística - Algunas propiedades

- La *media* es una medida de tendencia central
- La *varianza* mide la dispersión de los datos respecto a la media
- La *covarianza* relaciona las variaciones en $\vec{x}$ con las de $\vec{y}$, en relación con sus respectivas medias

Covarianzas

Las cosas se simplifican cuando las medias son 0

- Si $\vec{x} = [-1, 2, 1, -2]$ y $\vec{y} = [1, -1, 1, -1]$

$$\implies \text{cov}(\vec{x}, \vec{y}) = \frac{(-1)(1) + (2)(-1) + (1)(1) + (-2)(-1)}{3} = \frac{0}{3} = 0$$

- Si $\vec{x} = [-1, 2, 1, -2]$ y $\vec{y} = [-1, 1, 1, -1]$

$$\implies \text{cov}(\vec{x}, \vec{y}) = \frac{(-1)(-1) + (2)(1) + (1)(1) + (-2)(-1)}{3} = \frac{6}{3} = 2$$

- El signo de covarianza es la pendiente de la relación
- La covarianza igual a 0 implica no correlacionamiento

Matriz de Covarianza

Sea

$$M_{m\times n} = \begin{bmatrix} \text{altura}_1 & \text{altura}_2 & \dots & \text{altura}_n \\ \text{peso}_1 & \text{peso}_2 & \dots & \text{peso}_n \end{bmatrix}$$

y

$$C_{m\times m} = \{c_{ij}\} = \frac{1}{n-1} MM^T$$

Para esta definición de matriz de covarianza, la media de cada tipo de medición debe ser 0

Matriz de Covarianza (continuación)

- Elementos en la diagonal de C
  - Por lo general, las grandes variaciones son las más interesantes
  - Lo ideal: algunos grandes y la mayoría pequeños
- Elementos fuera de la diagonal de C
  - Covarianza entre tipos de medición
  - Si $\text{cov} = 0 \implies \text{no correlacionada}$
  - Si $\text{cov} \neq 0 \implies \text{redundancia}$
  - Lo ideal: que los elementos fuera de la diagonal sean todos 0

Análisis de Componentes Principales

- PCA es una poderosa técnica de aprendizaje automático basada en métodos de álgebra lineal.
- Encuentra las dimensiones más significativas en un conjunto de datos. Reduce la dimensionalidad del problema con una pérdida mínima de información.
- La descomposición en valores singulares (SVD) es la forma más común de implementar el PCA.

La base vectorial original no es la más informativa

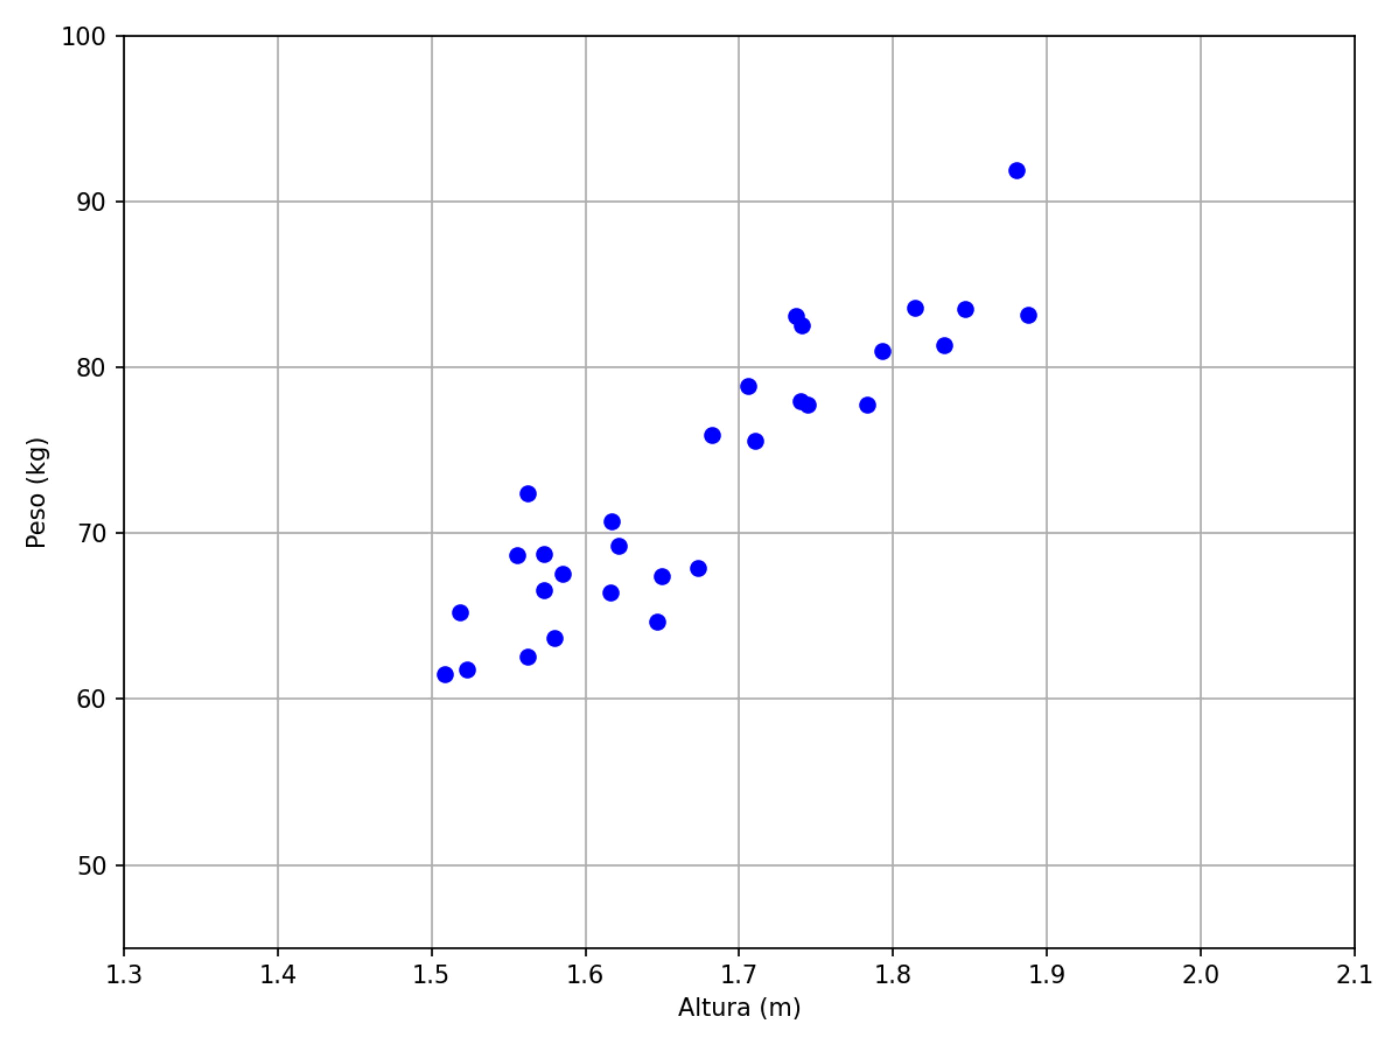

Alinear la base vectorial con los datos

- Línea roja es la dirección de la varianza máxima
- Reduce el "ruido"

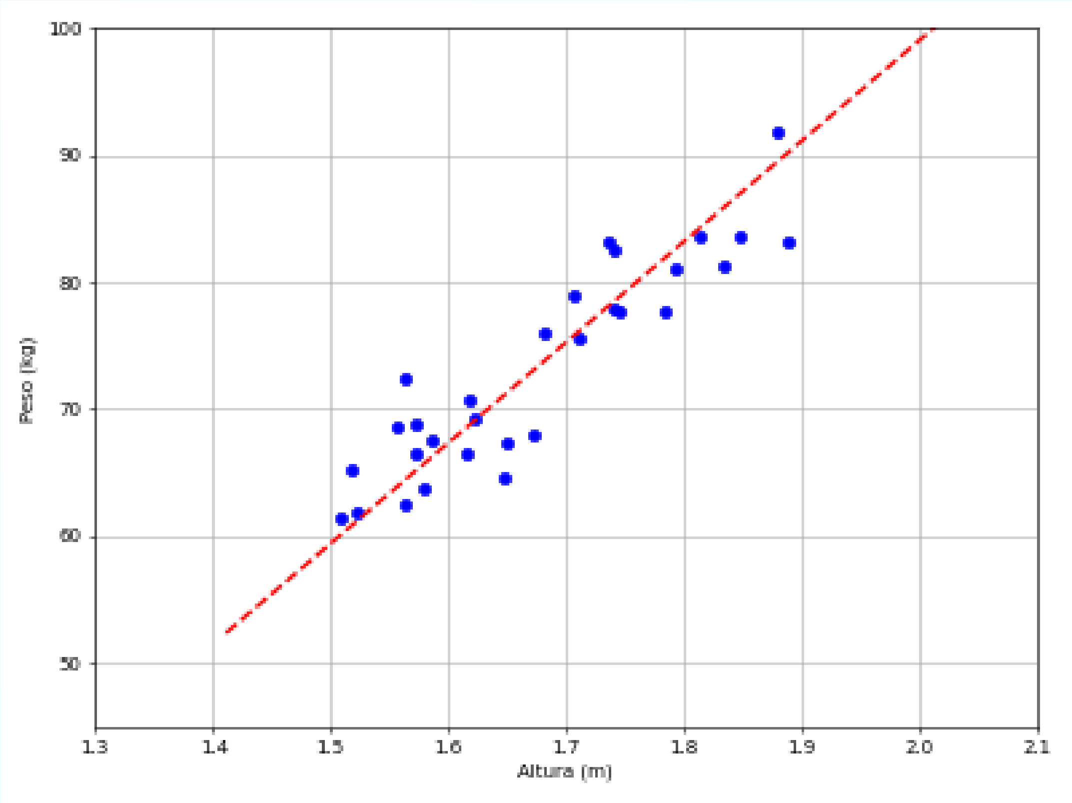

Análisis de Componentes Principales (PCA)

- La estructura de los datos define la dirección de los vectores
- La longitud cuantifica la varianza en cada dirección

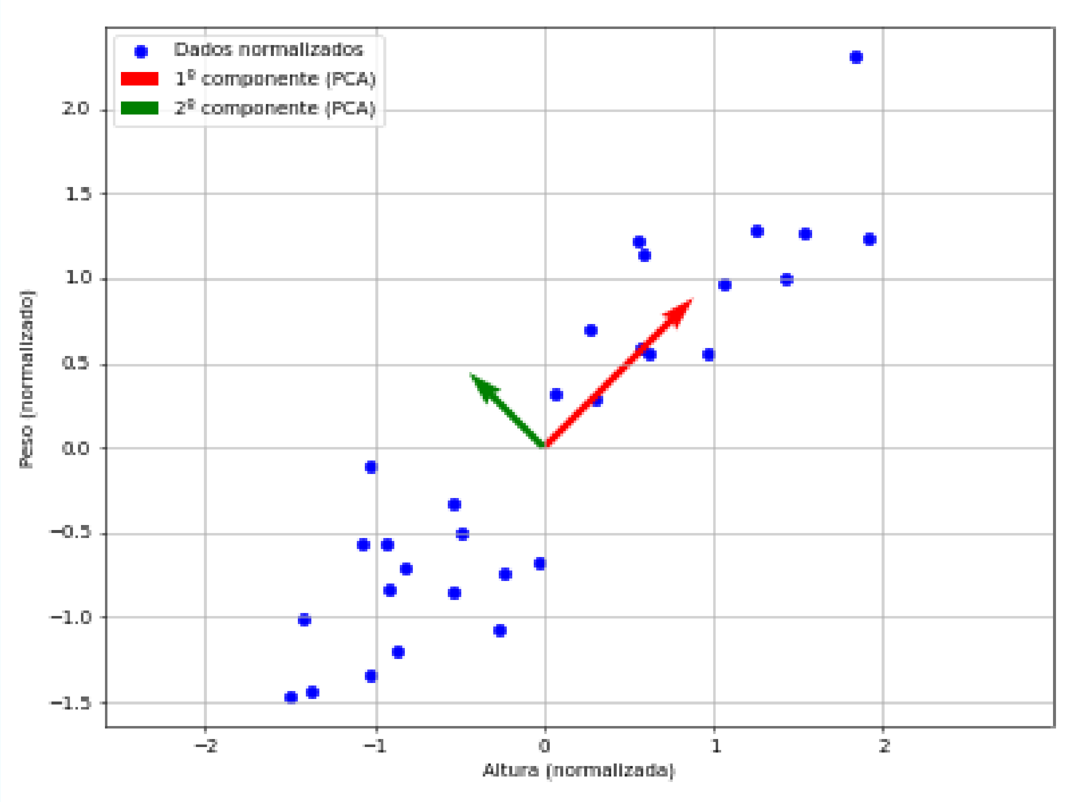

Idea básica del PCA

PCA alinea la base con las varianzas. Diagonalizando la matriz de covarianza C.

Para la diagonalización:

1. Elegir la dirección (dimensión) con desviación máxima
2. Encontrar la dirección con la varianza máxima que sea ortogonal a todas las direcciones seleccionadas anteriormente
3. Volver a 2 (hasta que no queden dimensiones)

Los vectores resultantes son los componentes principales

Intuición detrás del PCA

- Para conocer una ciudad, no es necesario visitar todas las calles
- Podemos reducir la dimensionalidad del problema

Suposiciones importantes del PCA

1. Linealidad
   - El cambio de base es una operación lineal
   - Pero, algunos procesos son inherentemente no lineales
2. Grandes varianzas son más *interesantes*
   - La varianza grande es *señal*, la pequeña es *ruido*
   - Pero, puede no ser válido para algunos problemas
3. Los componentes principales son ortogonales
   - Hace que el problema se resuelva de manera eficiente
   - Pero, no ortogonal es mejor en algunos casos

Éxito del PCA

- El vector rojo más largo es la *señal*. Más informativo que el vector corto
- Podemos ignorar el vector corto. Puede ser considerado "ruido"
- Reduce el problema de 2-D a 1-D

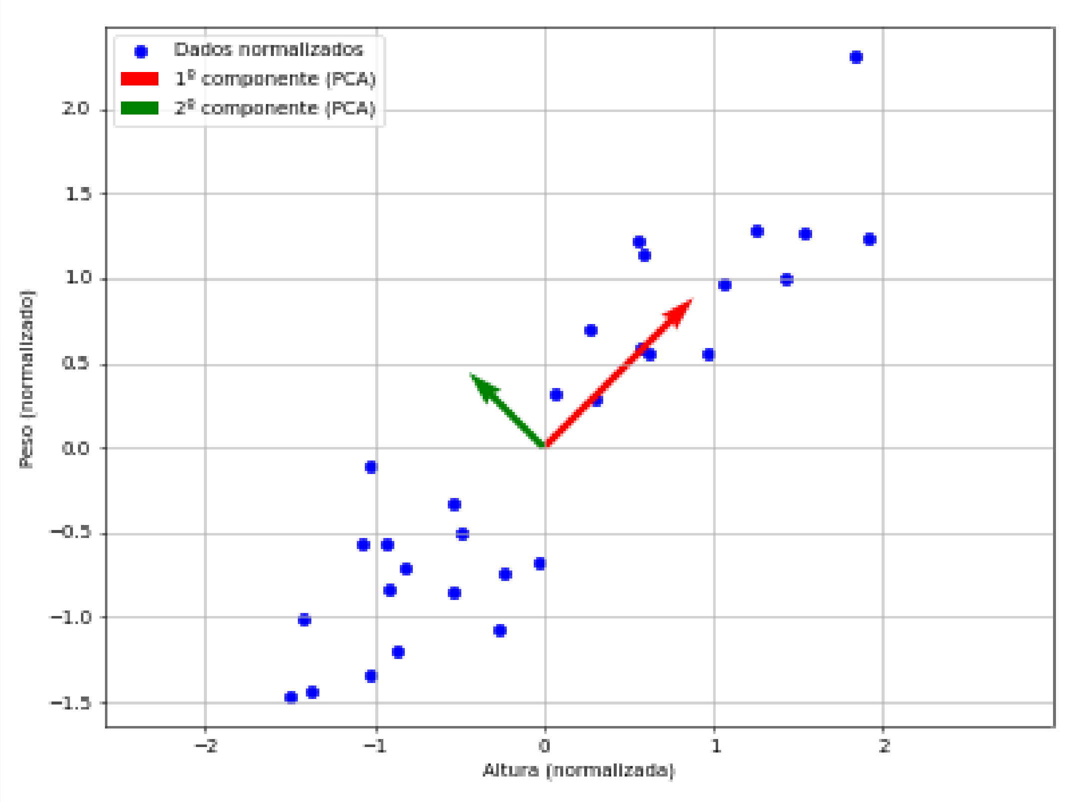

Limitaciones del PCA

- Datos distribuidos en formato de rueda. Resultados de PCA inútiles
  - El ángulo θ tiene toda la información
  - Pero θ es no lineal en relación a la base (x, y)
- Datos con patrones complejos que no pueden ser descritos por un modelo lineal
- PCA asume linealidad

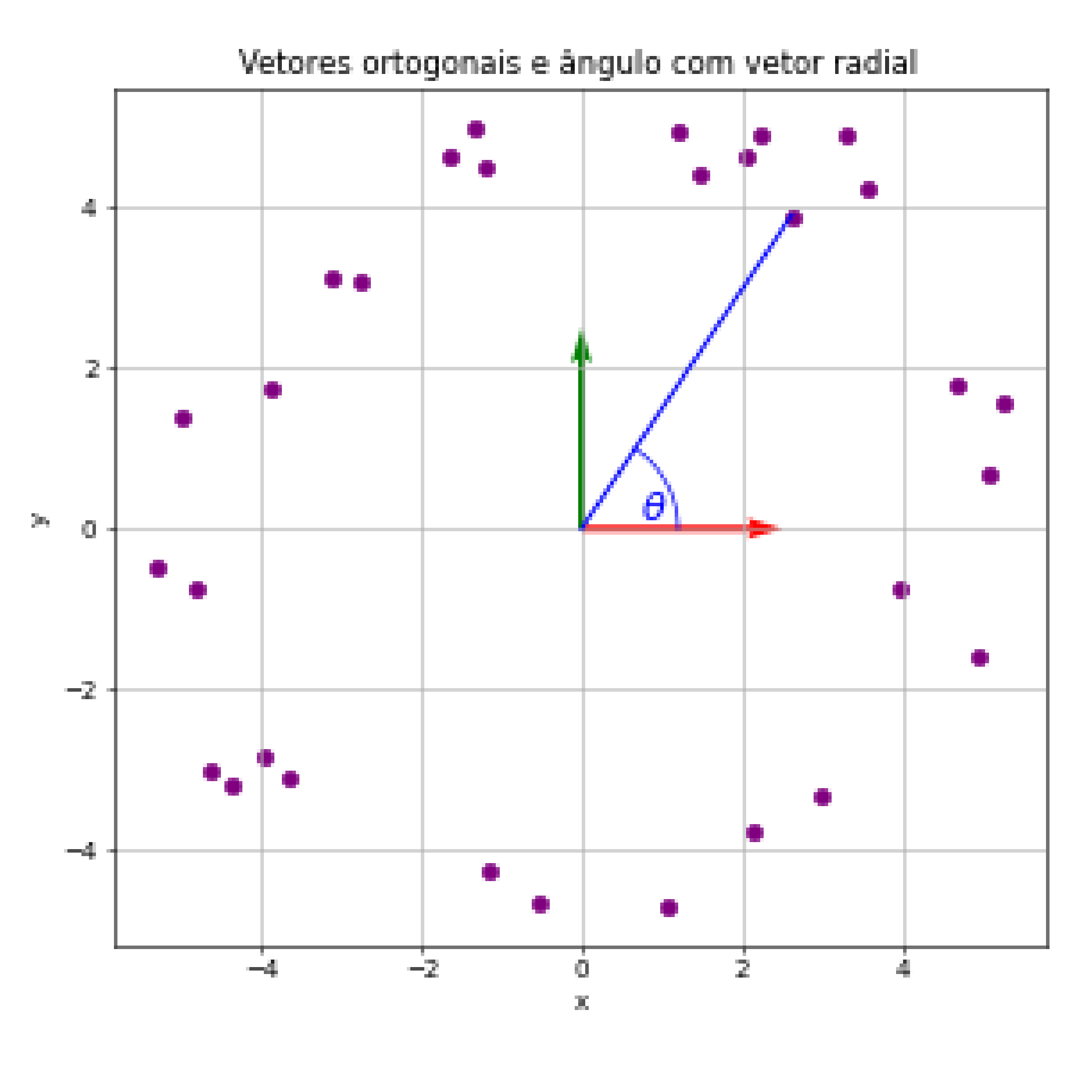

Resumen de PCA

- Organizar los datos en una matriz centralizada $M_{m \times n}$
  - Donde n es el número de *experimentos*
  - m *mediciones* por experimento
- Formar la matriz de covarianza $C_{m \times m} = \frac{1}{n-1} M M^T$
- Calcular los autovalores y autovectores de esa matriz de covarianza C. Cada autovector es de dimensión m
- Formar la matriz de autovectores V donde cada columna es un autovector
- El producto $M^T V$ es la matriz transformada de los datos, con matriz de covarianza diagonal

Descomposición en Valores Singulares

SVD - Singular Values Decomposition

- Es una forma elegante de encontrar los autovectores
- Sea la matriz de datos a ser analizada: $M_{m \times n}$
- SVD descompone la matriz como

$$M = U \Sigma V^T$$

Esto funciona en un entorno muy general.

SVD es una técnica general para encontrar componentes principales.

SVD y PCA

- SVD es una (mejor) manera de hacer PCA
- Una forma de calcular autovectores
- En la SVD, $M = U\Sigma V^T$, donde
    - Las columnas de U contienen los autovectores de MM^T
    - Las columnas de V contienen los autovectores de M^TM
    - Σ es diagonal y sus elementos son los valores singulares. Cada valor singular es la raiz cuadrada de uno de los autovalores.

Ejemplo

Tenemos una matriz de datos $X \in \mathbb{R}^{30\times 4}$. Cuatro medidas para treinta muestras :

$$X = \begin{bmatrix} 5.7 & 2.8 & 4.5 & 1.3 \\ 5.0 & 3.4 & 1.5 & 0.2 \\ 6.4 & 3.2 & 4.5 & 1.5 \\ 5.1 & 3.5 & 1.4 & 0.2 \\ 6.3 & 2.9 & 5.6 & 1.8 \\ 4.9 & 2.4 & 3.3 & 1.0 \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

$$Y = \begin{bmatrix} 1 & 0 & 1 & 0 & 2 & 1 & \cdots \end{bmatrix}$$

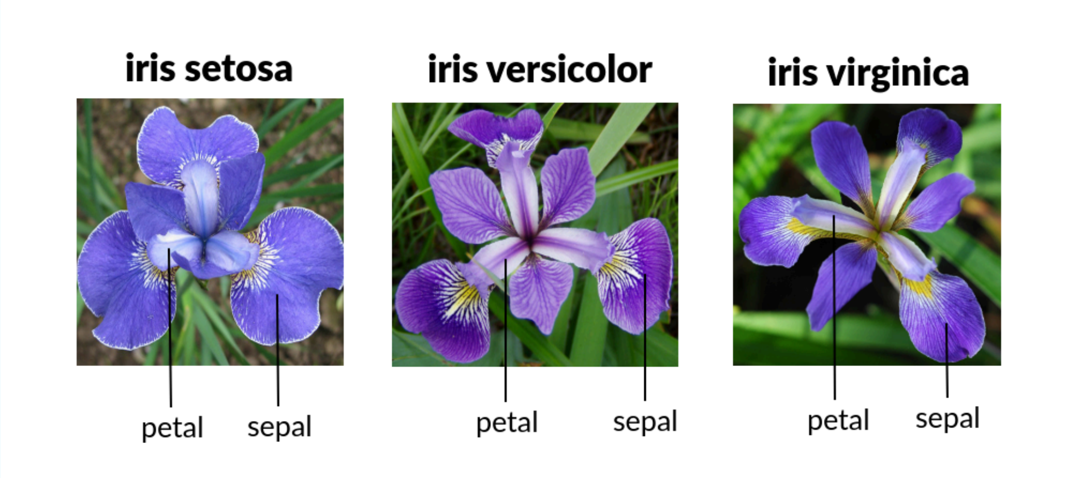

$col0$ y $col1$: longitud y ancho del sépalo

$col2$ y $col3$: longitud y ancho del pétalo

En Y: 0: setosa; 1: versicolor; 2: virginica

Dataset Iris con 30 muestras

Gráfico de dispersión segun la **longitud** y el **ancho** de los sépalos

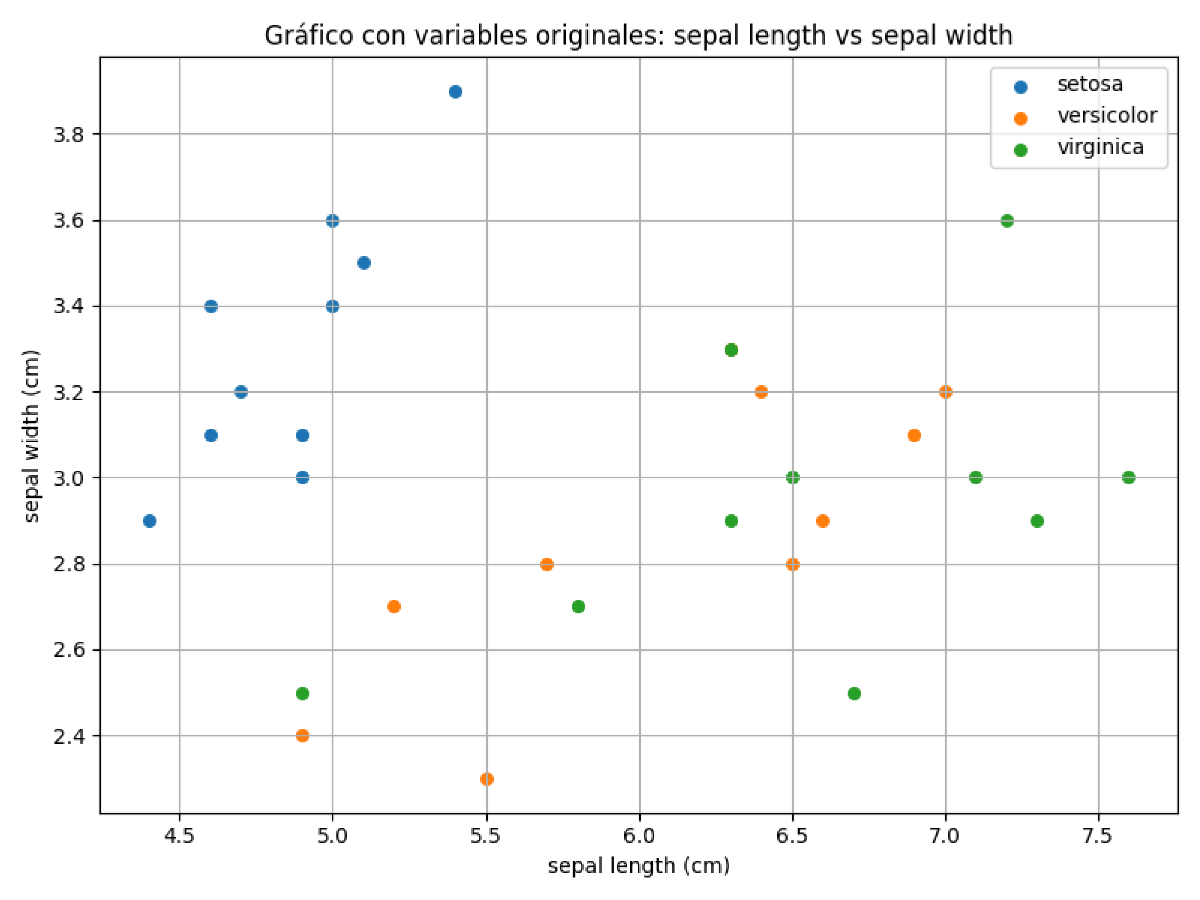

Implementación práctica con scikit-learn

1. Configuración inicial y carga de datos

```python
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris
from sklearn.decomposition import PCA

# Cargar el dataset Iris
X, y = load_iris(return_X_y=True)
```

Información del dataset:

- $X \in \mathbb{R}^{150\times 4}$: matriz de datos con 150 muestras y 4 características (longitud y ancho del sépalo y pétalo)
- $y \in \{0, 1, 2\}^{150}$: etiquetas de clase (Setosa, Versicolor, Virginica)

2. Proceso interno del PCA en scikit-learn

Paso 1: Centrado automático de datos

Importante: scikit-learn centra automáticamente los datos antes de aplicar PCA. Esto significa que:

$$\bar{x}_j = \frac{1}{n}\sum_{i=1}^{n} X_{ij} \quad \text{(media de la característica } j\text{)}$$

$$X_{\text{centrada}} = X - \bar{x} \quad \text{(matriz centrada)}$$

Paso 2: Descomposición SVD

scikit-learn usa la **descomposición SVD** de la matriz centrada:

$$X_{\text{centrada}} = U\Sigma V^T$$

Componentes de la descomposición:

- $U \in \mathbb{R}^{150\times 4}$: vectores singulares izquierdos (no se almacenan)
- $\Sigma \in \mathbb{R}^{4\times 4}$: valores singulares en la diagonal
- $V \in \mathbb{R}^{4\times 4}$: **componentes principales** (filas de V)

Paso 3: Selección de componentes

Para reducir a 2 dimensiones, se toman las primeras 2 filas de V:

$$V_2 = \begin{bmatrix} v_1^T \\ v_2^T \end{bmatrix} \in \mathbb{R}^{2\times 4}$$

Paso 4: Proyección de datos

Los datos transformados se obtienen como:

$$X_{\text{PCA}} = X_{\text{centrada}} \cdot V_2^T \in \mathbb{R}^{150\times 2}$$

3. Implementación práctica

```
# Crear y ajustar el modelo PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X)

print(f"Forma de los datos transformados: {X_pca.shape}")
```

Resultado: Los datos se transforman de $\mathbb{R}^{150\times 4}$ a $\mathbb{R}^{150\times 2}$

4. Visualización de resultados

```python
# Crear el gráfico de dispersión
plt.figure(figsize=(10, 6))
colors = ['red', 'green', 'blue']
labels = ['Setosa', 'Versicolor', 'Virginica']

for i in range(3):
    mask = y == i
    plt.scatter(X_pca[mask, 0], X_pca[mask, 1],
                c=colors[i], label=labels[i], alpha=0.7)

plt.xlabel('Primer Componente Principal')
plt.ylabel('Segundo Componente Principal')
plt.title('Dataset Iris después del PCA')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```

Gráfico de dispersión

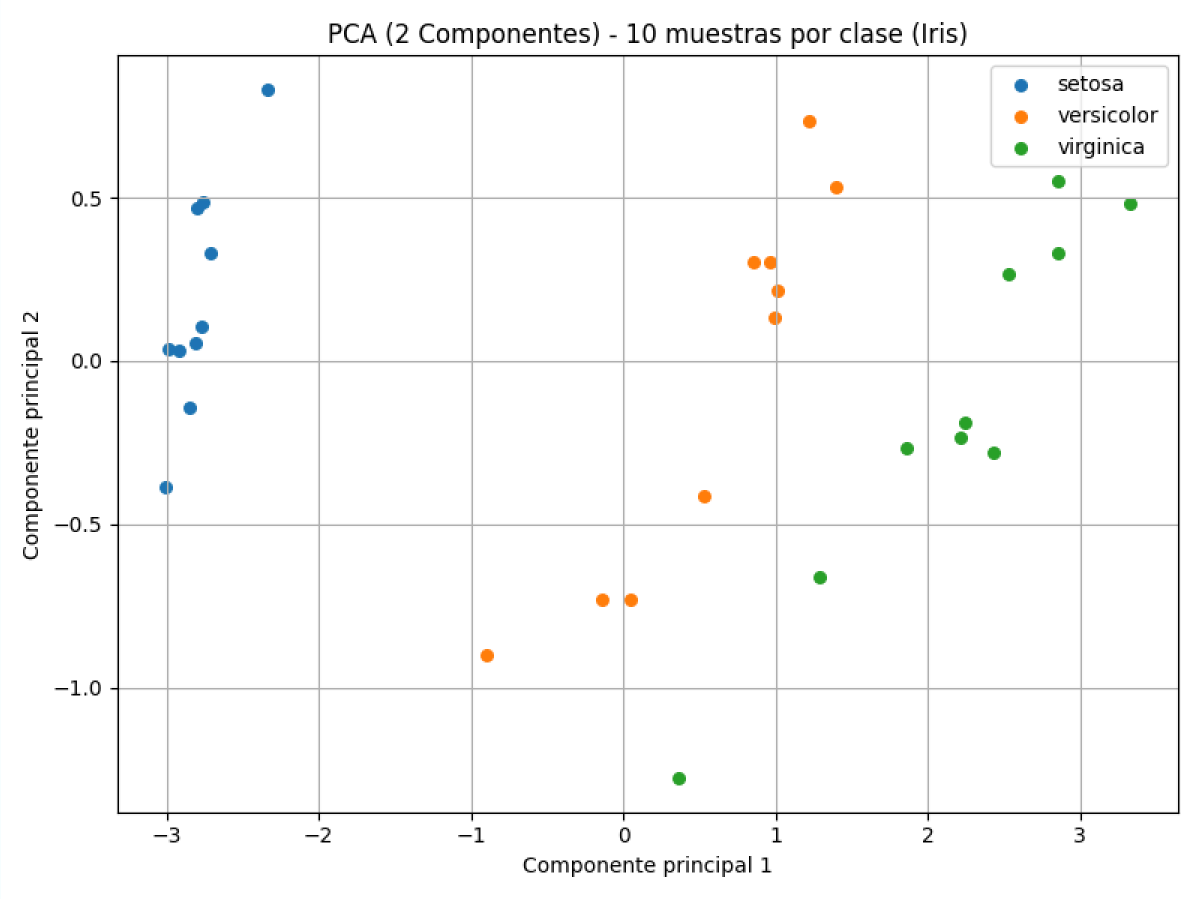

5. Análisis de varianza explicada

```python
# Obtener información de varianza
varianza_explicada = pca.explained_variance_ratio_
varianza_total = np.sum(varianza_explicada)

print(f"Varianza explicada por componente: {np.round(varianza_explicada, 4)}")
print(f"Varianza total explicada: {np.round(varianza_total, 4)}")
print(f"Porcentaje de información conservada: {varianza_total*100:.2f}%")
```

Interpretación de los resultados:

- Primer componente: 92.56% de la varianza
- Segundo componente: 5.58% de la varianza
- **Total conservado: 98.14%** de la información original

6. Fundamentos matemáticos de la varianza explicada

Relación con autovalores

Los valores singulares σ_i de la SVD están relacionados con los autovalores λ_i de la matriz de covarianza:

$$\lambda_i = \frac{\sigma_i^2}{n-1}$$

Cálculo de varianza explicada

La varianza explicada por el componente i es:

$$\text{Varianza explicada}_i = \frac{\lambda_i}{\sum_{j=1}^{p} \lambda_j} = \frac{\sigma_i^2}{\sum_{j=1}^{p} \sigma_j^2}$$

7. Criterios para seleccionar el número de componentes

Método 1: Varianza acumulada

```python
# Calcular varianza acumulada
varianza_acumulada = np.cumsum(pca.explained_variance_ratio_)
print(f"Varianza acumulada: {np.round(varianza_acumulada, 4)}")

# Encontrar número de componentes para 95% de varianza
n_comp_95 = np.argmax(varianza_acumulada >= 0.95) + 1
print(f"Componentes necesarios para 95% de varianza: {n_comp_95}")
```

Método 2: Gráfico de codo (Scree plot)

```python
# Crear gráfico de varianza explicada
plt.figure(figsize=(10, 6))
plt.plot(range(1, len(varianza_explicada)+1), varianza_explicada, 'bo-')
plt.xlabel('Número de Componentes')
plt.ylabel('Varianza Explicada')
plt.title('Gráfico de Codo - Varianza Explicada por Componente')
plt.grid(True, alpha=0.3)
plt.show()
```

Gráfico de codo

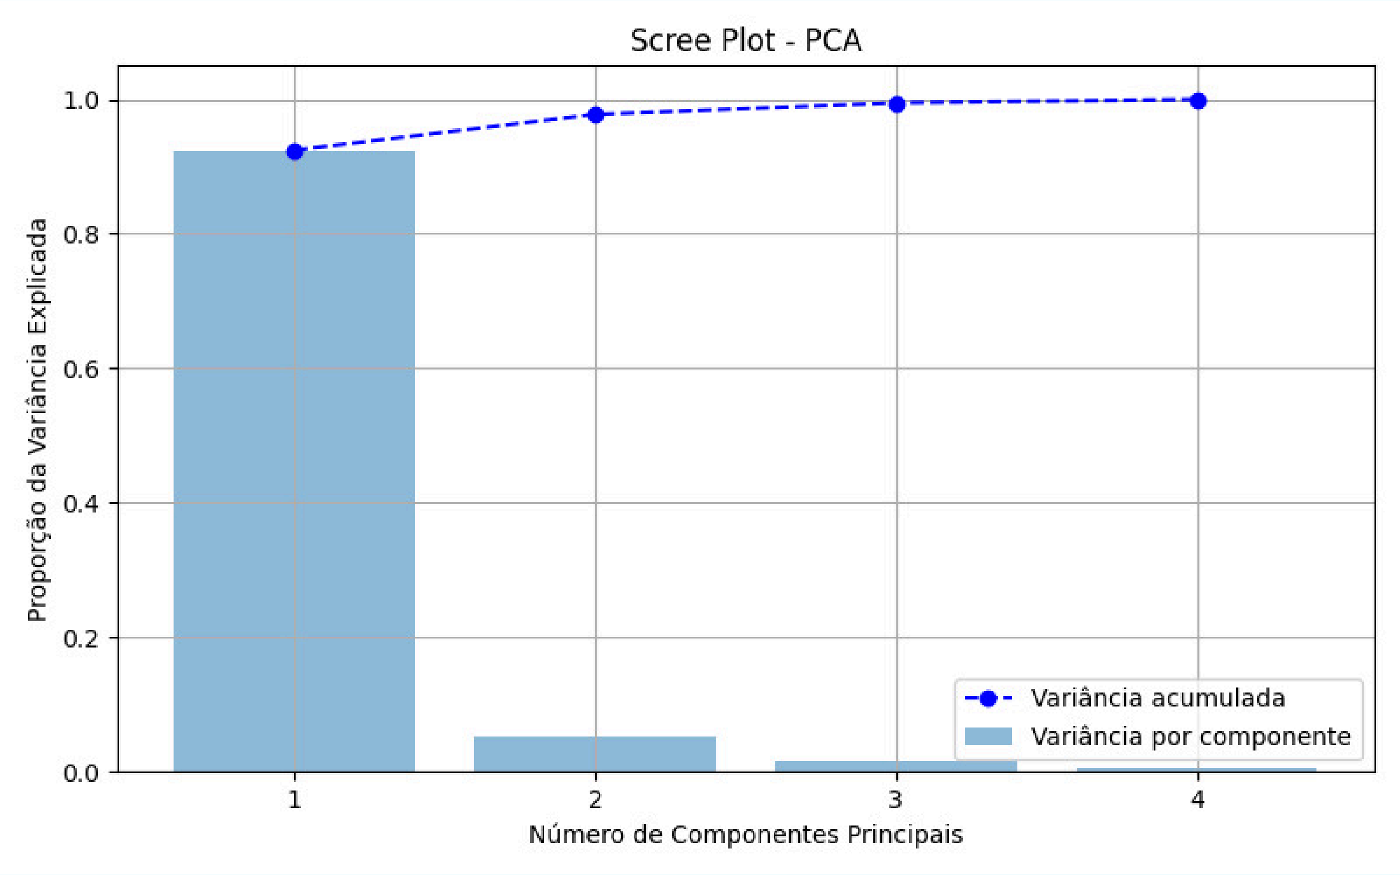

8. Acceso a los componentes principales

```
# Obtener los componentes principales
componentes = pca.components_
print(f"Forma de los componentes: {componentes.shape}")
print(f"Primer componente: {componentes[0]}")
print(f"Segundo componente: {componentes[1]}")

# Interpretación: cada componente es una combinación lineal de las características originales
```

Interpretación: Los componentes principales muestran cómo se combinan las características originales para formar las nuevas dimensiones.

Link material de apoyo

Fin